

# Übung 5

## Computational Physics III

Matthias Plock (552335)

Paul Ledwon (561764)

14. Juni 2018

### Inhaltsverzeichnis

## 1 Conjugate-Gradient auf der GPU

Die Funktionen aus den letzten Übungen wurden so in das Grundgerüst von Uebung5.zip eingefügt, dass nun der Conjugate-Gradient-Algorithmus parallelisiert auf der GPU ausgeführt werden kann. Für verschiedene Gittergrößen  $N$  wurden die Laufzeiten bei verschiedenen execution-configurations und 10 Durchläufen ermittelt. Aus dem Durchschnitt der Laufzeiten für ein festes  $N$  wurde mit der schnellsten execution-configuration der Speedup berechnet. Die Ergebnisse sind in Abb. 1 dargestellt. Mit steigender Gittergrösse steigt auch der Speedup, auch wenn dieser erst ab  $N = 512$  den Wert 1 übersteigt.

Es wird vermutet, dass die GPU-Implementierung nicht optimal ist, da bei der Benutzung von nvprof auffiel, dass ein Grossteil der Laufzeit durch die Ausführung von den Unroll-Funktionen bei der Berechnungen der Skalarprodukte verursacht wird. Um ein Skalarprodukt zu berechnen, wird die Unroll-Funktion zweimal ausgeführt. Möglicherweise wäre es effizienter, nur eine Unroll-Funktion auszuführen und dann das vergleichsweise kleine Array auf dem Host zu berechnen.

## 2 Amdahlsches Gesetz

Das Amdahlsche Gesetz besagt, dass für den Speedup  $S_p(N) = \frac{T_s(N)}{T_p(N)}$  gilt

$$S_p(N) \leq \frac{1}{f}, \quad (1)$$

wobei  $f$  der Anteil des Problems ist, der seriell ausgeführt werden muss.

### 2.1 Beweis

Wir teilen die Laufzeit der seriellen Lösung des Problems auf in

$$T_s(N) = t_s + t_p^s = f \cdot T_s(N) + (1 - f) \cdot T_s(N). \quad (2)$$

Analog gilt dann für die Laufzeit des parallelen Problems

$$T_p(N) = t_s + t_p^p = f \cdot T_s(N) + t_p^p. \quad (3)$$

Hierbei ist  $t_s$  die Laufzeit, die benötigt wird um den seriellen Anteil des Problems zu lösen.  $t_p^s$  und  $t_p^p$  sind die Laufzeiten, die das beste serielle bzw. parallelisierte Programm zur Lösung des parallelisierbaren Anteils des Problems benötigen. Theoretisch kann  $t_p^p$  auf die Dauer einer Operation reduziert werden, für den Fall, dass man eine ausreichende Menge an Threads zur Verfügung hat.

Setzt man (2) und (3) in die Definition des Speedups ein erhält man

$$\begin{aligned} S_p(N) &= \frac{f \cdot T_s(N) + (1 - f) \cdot T_s(N)}{f \cdot T_s(N) + t_p^p} \leq \frac{f \cdot T_s(N) + (1 - f) \cdot T_s(N)}{f \cdot T_s(N)} \\ &= \frac{1 + \frac{1-f}{f}}{1} = \frac{f + 1 - f}{f} = \frac{1}{f} \end{aligned}$$